

LED

Ligando dados, pessoas e conhecimento

ELT para base pública de corridas de táxi em Nova York

Antonio Rodrigues Pinheiro Carolino
Bruna Freitas da Silva
Fernando Corrêa Gambôa Pereira dos Santos
Gabriel Valença Mayerhofer

Recife, 2026

Sumário

1. Perfilamento.....	1
1.1 Volumes e Tipos.....	1
1.2 Nulidade.....	2
1.3 Cardinalidade.....	3
1.4 Domínio Esperado.....	4
1.5 Distribuição para Verificação de Outliers.....	11
1.6 Duplicidade.....	11
1.7 Cruzamento Simples Entre Colunas.....	12
2. Tratamento.....	14
2.1 Decisões de Tratamento.....	14
2.2 Limpeza.....	15
3. Modelagem.....	15
4. Consultas Analíticas.....	16
4.1 Financeiro.....	16
4.2 Operacional.....	16
4.3 Localização.....	16
4.4 Data.....	17

Entender o bd

- Cada coluna
- Cada linha
- Definir o que fazer com nulls em cada coluna

1. Perfilamento

1.1 Volumes e Tipos

Objetivo: Confirmar quantas linhas a base bruta possui, se os tipos que o DuckDB infere diretamente do Parquet fazem sentido com o dicionário de dados oficial, e se todas as colunas têm o mesmo volume de preenchimento.

- Consulta 1: Volume total de linhas
`SELECT COUNT(*) AS total_linhas FROM raw_taxi;`
- Consulta 2: Tipos inferidos pelo DuckDB para cada coluna
`DESCRIBE raw_taxi;`
- Consulta 3: Volume (linhas não nulas) por coluna
`SELECT COUNT(*) AS total_linhas,
COUNT(VendorID) AS vendorid_preenchidos,
COUNT(tpep_pickup_datetime) AS pickup_preenchidos,
COUNT(tpep_dropoff_datetime) AS dropoff_preenchidos,
COUNT(passenger_count) AS passenger_count_preenchidos,
COUNT(trip_distance) AS trip_distance_preenchidos, COUNT(RatecodeID)
AS ratecodeid_preenchidos,
COUNT(store_and_fwd_flag) AS store_and_fwd_flag_preenchidos,
COUNT(PULocationID) AS pulocationid_preenchidos,
COUNT(DOLocationID) AS dolocationid_preenchidos,
COUNT(payment_type) AS payment_type_preenchidos,
COUNT(fare_amount) AS fare_amount_preenchidos,
COUNT(extra) AS extra_preenchidos, COUNT(mta_tax) AS
mta_tax_preenchidos, COUNT(tip_amount) AS tip_amount_preenchidos,
COUNT(tolls_amount) AS tolls_amount_preenchidos,
COUNT(improvement_surcharge) AS improvement_surcharge_preenchidos,
COUNT(total_amount) AS total_amount_preenchidos,
COUNT(congestion_surcharge) AS congestion_surcharge_preenchidos,
COUNT(Airport_fee) AS airport_fee_preenchidos FROM raw_taxi;`
- Conclusões da análise
 - Volume total: a base bruta possui 2.964.624 linhas.
 - Tipos batem com o dicionário: o DuckDB inferiu os tipos direto do Parquet, sem nenhum CAST manual, e todos fazem sentido — datas

(tpep_pickup_datetime, tpep_dropoff_datetime) como TIMESTAMP nativo, códigos (VendorID, RatecodeID, payment_type) como valores numéricos inteiros, e campos monetários como DOUBLE.

1.2 Nulidade

Verificar percentual de nulos total, por coluna, verificar se é nulo mesmo ou contexto

- Pergunta: Quais colunas têm valores nulos, e em que proporção?

• Consulta 1:

```
SELECT
    COUNT(*) AS total,
    COUNT(*) FILTER (WHERE passenger_count IS NULL) AS
nulos_passenger_count,
    COUNT(*) FILTER (WHERE RatecodeID IS NULL) AS nulos_ratecodeid,
    COUNT(*) FILTER (WHERE store_and_fwd_flag IS NULL) AS
nulos_store_fwd_flag,
    COUNT(*) FILTER (WHERE congestion_surcharge IS NULL) AS
nulos_congestion,
    COUNT(*) FILTER (WHERE Airport_fee IS NULL) AS nulos_airport_fee
FROM raw_trips;
```

Resultado 1:

Coluna	Total	Nulos	%	
passenger_count	2.964.624	140.162	4,73%	
RatecodeID	2.964.624	140.162	4,73%	
store_and_fwd_flag	2.964.624	140.162	4,73%	
congestion_surcharge	2.964.624	140.162	4,73%	
Airport_fee	2.964.624	140.162	4,73%	

Achado 1: As 5 colunas têm exatamente o mesmo número de nulos (140.162), indicando que são as *mesmas linhas* nulas nas 5 colunas simultaneamente.

- Consulta 2 (investigação adicional — cruzamento com VendorID):

```
SELECT
    VendorID,
    COUNT(*) AS total,
    COUNT(*) FILTER (WHERE passenger_count IS NULL) AS nulos
FROM raw_trips
GROUP BY VendorID
ORDER BY VendorID;
```

Resultado 2:

VendorID	Total	Nulos	% nulo
1	729.732	48.455	6,64%
2	2.234.632	91.447	4,09%
6	260	260	100%

Achado 2: O VendorID 6 tem 100% das suas corridas nulas nesse grupo de colunas, todo o fornecedor não reporta esses campos, reforçando a hipótese de que se trata de um sistema de reporte diferente (não um erro aleatório). Já os VendorID 1 e 2 têm nulidade parcial (4-7%), compatível com falhas pontuais de reporte, não um padrão sistemático por fornecedor.

1.3 Cardinalidade

Objetivo: Contar quantos valores distintos cada coluna assume e comparar com o que a regra de negócio do dicionário de dados esperaria

- Consulta 1: Cardinalidade de todas as colunas de raw_taxi

```
SELECT COUNT(*) AS total_linhas,
COUNT(DISTINCT VendorID) AS card_vendorid,
COUNT(DISTINCT tpep_pickup_datetime) AS card_pickup_datetime,
COUNT(DISTINCT tpep_dropoff_datetime) AS card_dropoff_datetime,
COUNT(DISTINCT passenger_count) AS card_passenger_count,
COUNT(DISTINCT trip_distance) AS card_trip_distance,
COUNT(DISTINCT RatecodeID) AS card_ratecodeid,
COUNT(DISTINCT store_and_fwd_flag) AS card_store_and_fwd_flag,
COUNT(DISTINCT PULocationID) AS card_pulocationid,
COUNT(DISTINCT DOLocationID) AS card_dolocationid,
COUNT(DISTINCT payment_type) AS card_payment_type,
COUNT(DISTINCT fare_amount) AS card_fare_amount,
COUNT(DISTINCT extra) AS card_extra,
COUNT(DISTINCT mta_tax) AS card_mta_tax,
COUNT(DISTINCT tip_amount) AS card_tip_amount,
COUNT(DISTINCT tolls_amount) AS card_tolls_amount,
COUNT(DISTINCT improvement_surcharge) AS
card_improvement_surcharge, COUNT(DISTINCT total_amount) AS
card_total_amount,
COUNT(DISTINCT congestion_surcharge) AS card_congestion_surcharge,
COUNT(DISTINCT Airport_fee) AS card_airport_fee FROM raw_taxi;
```
- Consulta 2: Cardinalidade da tabela de referência de zonas

```
SELECT COUNT(*) AS total_zonas,
COUNT(DISTINCT LocationID) AS card_locationid,
```

```
COUNT(DISTINCT Borough) AS card_borough,
COUNT(DISTINCT Zone) AS card_zone,
COUNT(DISTINCT service_zone) AS card_service_zone FROM
raw_taxi_zone;
```

1.4 Domínio Esperado

Os valores estão dentro do esperado do dicionário de dados (por exemplo valores de distância negativos).

1.4.1 VendorID

De acordo com o dicionário de dados, a coluna VendorID se refere às empresas responsáveis pelo envio do registro, as empresas são classificadas em IDs de 1, 2, 6, 7. Para verificar a consistência dos dados foram realizadas consultas SQL com o objetivo de verificar os valores existentes na tabela, quantas ocorrências existem para cada valor e se existem domínios fora do escopo esperado.

- Consulta 1: Valores distintos
SELECT DISTINCT VendorID FROM raw_taxi ORDER BY VendorID;
- Consulta 2: Quantidade ocorrências por valor
SELECT VendorID, COUNT(*) AS quantidade FROM raw_taxi GROUP BY VendorID ORDER BY VendorID;
- Consulta 3: Verificação de valores fora do domínio esperado
SELECT * FROM raw_taxi WHERE VendorID NOT IN (1, 2, 6, 7);

Com base nisso, foi possível perceber que a tabela possui apenas os valores 1, 2 e 6, mantendo o esperado com base no dicionário, mas mostrando que a empresa 7, referente a Helix, não realizou registros de viagens, o que não caracteriza um erro. Também foi possível analisar que as empresas possuem altas quantidades de registro, sendo a empresa 2 a maior detentora desses registros com 2234632 registros. Ao analisarmos a existência de domínios fora do escopo, teve o resultado 0, mostrando uma alta consistência entre o dicionário e a coluna.

1.4.2 tpep_pickup_datetime e tpep_dropoff_datetime

No dicionário de dados as colunas “tpep_pickup_datetime” e “tpep_dropoff_datetime” tem o objetivo de mostrar o instante no qual o taxímetro iniciou e terminou. No dicionário não há especificação de valores, no entanto, o desafio proposto se baseia em valores de janeiro de 2024. Com base nisso, buscamos analisar a existência de valores nulos, valores igual a 0, e o horário de término das corridas.

- Consulta 2: Existência de valores nulos
SELECT COUNT(*) AS nulos FROM raw_taxi WHERE tpep_pickup_datetime IS NULL;
- SELECT COUNT(*) FROM raw_taxi WHERE tpep_dropoff_datetime IS NULL;

- Consulta 3: Existência de ano diferente de 2024
 SELECT * FROM raw_taxi WHERE YEAR(tpep_pickup_datetime) != 2024;

 SELECT * FROM raw_taxi WHERE YEAR(tpep_dropoff_datetime) != 2024;
- Consulta 4: Datas diferentes de Janeiro
 SELECT * FROM raw_taxi WHERE MONTH(tpep_pickup_datetime) <> 1
 AND YEAR(tpep_pickup_datetime) = 2024;

 SELECT tpep_dropoff_datetime FROM raw_taxi WHERE
 MONTH(tpep_dropoff_datetime) <> 1 AND YEAR(tpep_dropoff_datetime) =
 2024 LIMIT 20;
- Consulta 5: Término da corrida
 SELECT * FROM raw_taxi WHERE tpep_dropoff_datetime <
 tpep_pickup_datetime;
- Consulta 6: Corridas iniciadas em Fevereiro
 SELECT * FROM raw_taxi WHERE YEAR(tpep_pickup_datetime) = 2024
 AND MONTH(tpep_pickup_datetime) = 2;

Com base nas consultas foi possível avaliar que as tabelas não possuem valores nulos, mas possuem datas diferentes de 2024 nos momentos de início e fim da corrida. Também foi possível perceber que há momentos de fim da corrida em Fevereiro, no entanto esse é um comportamento normal, sendo necessário retirar apenas as corridas iniciadas em Fevereiro. Além disso, foi encontrado horários de chegada menores que horários de início, mostrando inconsistência de informações. Essas análises levantam questionamentos sobre a limpeza dos dados, como a necessidade de se retirar os anos diferentes de 2024 e os meses diferentes de Janeiro.

1.4.4 passenger_count

O dicionário de dados também trás a coluna “passenger_count” a qual se refere a quantidade de passageiros no veículo. No dicionário não há especificação de valores para a referida tabela, mas ela trás a necessidade de verificações de quantidade e nulidade de passageiros.

- Consulta 1: Existência de valores negativos
 SELECT COUNT(*) FROM raw_taxi WHERE passenger_count < 0;
- Consulta 2: Valores iguais a 0
 SELECT passenger_count FROM raw_taxi WHERE passenger_count = 0;

Com base nisso, foram feitas consultas que mostraram a existência de

valores nulos, o que não é exatamente um erro, mas impede a verificação total de passageiros naquele período. No entanto, foi possível perceber a existência de passageiros iguais a 0, o que pode ou não ser considerado um erro, uma vez que não há especificação de quantidade pelo dicionário e o motorista pode ter esquecido de informar.

1.4.5 trip_distance

No dicionário de dados a coluna “trip_distance” tem o objetivo de mostrar a distância percorrida informada pelo taxímetro. No dicionário não há especificação de valores para a referida tabela, mas ela trás a necessidade de verificações de valores nulos, negativos, máximos e mínimos.

- Consulta 1: Valores nulos
SELECT SUM(CASE WHEN trip_distance IS NULL THEN 1 ELSE 0 END)
AS trip_distance FROM raw_taxi;
- Consulta 2: Valores negativos
SELECT * FROM raw_taxi WHERE trip_distance < 0;
- Consulta 3: Valor máximo
SELECT MIN(trip_distance), MAX(trip_distance) FROM raw_taxi;
- Consulta 4: Tempo percorrido pelo preço
SELECT trip_distance, fare_amount, total_amount, tpep_pickup_datetime,
tpep_dropoff_datetime FROM raw_taxi ORDER BY trip_distance DESC LIMIT
10;

A análise mostrou que a coluna não possui valores nulos ou negativos. Em relação às distâncias máximas e mínimas percorridas, foi encontrado 0 como distância mínima e 312722.3 como máxima. Os resultados permite perceber que a tabela está de acordo com o dicionário de dados, no entanto, o valor máximo se mostra irrealista podendo ser um erro de coleta ou digitação, por tanto, para verificação foi feita uma consulta extra (consulta 4), verificando a distância percorrida com o tempo de viagem e o valor cobrado. A consulta 4 evidenciou que a distância máxima se mostrou inconsistente uma vez que foi encontrado um registro com distância de 312.722,3 milhas, duração de 13 minutos e valor total de US\$22,15, sendo irrealista e necessitando de avaliação de tratamento.

1.4.6 RatecodeID

De acordo com o dicionário de dados, a coluna RatecodeID se refere ao tipo de tarifa, os tipos são classificados em 1, 2, 3, 4, 5, 6, 99. Para a análise da tabela foram feitas consultas relacionadas ao valores presentes, a existência de valores nulos e verificações de valores fora do escopo do dicionário

- Consulta 1: Valores distintos
SELECT DISTINCT RateCodeID FROM raw_taxi ORDER BY RateCodeID;

- Consulta 2: Valores nulos
SELECT SUM(CASE WHEN RatecodeID IS NULL THEN 1 ELSE 0 END) AS RatecodeID FROM raw_taxi;
- Consulta 3: Verificação de valores fora do domínio esperado
SELECT * FROM raw_taxi WHERE RatecodeID NOT IN (1, 2, 3, 4, 5, 6, 99);

Com base na análise foi possível perceber que os valores estão de acordo com o dicionário. No entanto, existem registros de valores nulos, o que não é necessariamente um erro. Portanto, há a necessidade de verificar se o null será mentindo ou retirado

1.4.7 store_and_fwd_flag

De acordo com o dicionário de dados, a coluna “store_and_fwd_flag” indica se o registro da viagem foi retido na memória do veículo antes de ser enviado ao fornecedor, os tipos são classificados em “Y” e “N”. Para a análise da tabela foram feitas consultas relacionadas aos valores presentes, a existência de valores nulos e verificações de valores fora do escopo do dicionário.

- Consulta 1: Valores distintos
SELECT DISTINCT store_and_fwd_flag FROM raw_taxi;
- Consulta 2: Valores nulos
SELECT SUM(CASE WHEN store_and_fwd_flag IS NULL THEN 1 ELSE 0 END) AS store_and_fwd_flag FROM raw_taxi;
- Consultas 3: Valores fora do escopo
SELECT * FROM raw_taxi WHERE store_and_fwd_flag IS NOT NULL AND store_and_fwd_flag NOT IN ('Y','N');

A análise da tabela permitiu perceber a existência de valores dentro do escopo do dicionário e nulos, que não se mostram necessariamente como um erro.

1.4.8 PULocationID e DOLocationID

No dicionário de dados as colunas “PULocationID ” e “DOLocationID” tem o objetivo de mostrar o momento de embarque e o de desembarque informados pelo taxímetro. No dicionário não há especificação de valores para as referidas tabelas, mas trás a necessidade de verificações de valores nulos, negativos e se tem correspondência com a tabela de referência.

- Consulta 1: Valores distintos
SELECT DISTINCT PULocationID FROM raw_taxi;

SELECT DISTINCT DOLocationID FROM raw_taxi;
- Consulta 2: Verifica se tem valores nulos

```
SELECT SUM(CASE WHEN PULocationID IS NULL THEN 1 ELSE 0 END)
AS PULocationID FROM raw_taxi;
```

```
SELECT SUM(CASE WHEN PULocationID IS NULL THEN 1 ELSE 0 END)
AS PULocationID FROM raw_taxi;
```

- Consulta 3: Valores fora do domínio esperado

```
SELECT DISTINCT t.PULocationID FROM raw_taxi t LEFT JOIN
raw_taxi_zone z ON t.PULocationID = z.LocationID WHERE z.LocationID IS
NULL;
```

```
SELECT DISTINCT t.DOLocationID FROM raw_taxi t LEFT JOIN
raw_taxi_zone z ON t.DOLocationID = z.LocationID WHERE z.LocationID IS
NULL;
```

Com base na análise realizada foi possível perceber a existência de valores nulos e que todas as localizações são correspondentes a tabela de referência. Não foram identificados valores inválidos, indicando que as colunas estão de acordo com o domínio esperado no dicionário.

1.4.9 payment_type

De acordo com o dicionário de dados, a coluna “payment_type” se refere às formas de pagamento, os tipos são classificados em 0, 1, 2, 3, 4, 5 e 6. Para a análise da tabela foram feitas consultas relacionadas aos valores presentes, a existência de valores nulos e verificações de valores fora do escopo do dicionário e a quantidade de registro para cada forma de pagamento.

- Consulta 1: Valores distintos

```
SELECT DISTINCT payment_type FROM raw_taxi ORDER BY
payment_type;
```

- Consulta 2: Valores nulos

```
SELECT SUM(CASE WHEN payment_type IS NULL THEN 1 ELSE 0 END)
AS payment_type FROM raw_taxi;
```

- Consulta 3: Valores fora do escopo

```
SELECT * FROM raw_taxi WHERE payment_type IS NOT NULL AND
payment_type NOT IN (0, 1, 2, 3, 4, 5, 6);
```

- Consulta 4: Quantidade de registros

```
SELECT payment_type, COUNT(*) AS quantidade FROM raw_taxi GROUP
BY payment_type ORDER BY payment_type;
```

A análise mostrou que a tabela não possui valores nulos e não há dados fora do escopo, além de não possuir todas as formas de pagamento, sendo os encontrados 0,1,2,3 e 4, essa informação não torna a tabela inválida, apenas

identifica que não foram feitos pagamentos de todas as formas possíveis. Também foi possível perceber que o registro 1 é o que possui maior quantidade, com 2319046 registros.

1.4.10 Valores Monetários

Os valores monetários encontrados nas colunas: fare_amount, extra, mta_tax, tip_amount, tolls_amount, improvement_surcharge, total_amount, congestion_surcharge, Airport_fee. Tais colunas são responsáveis por tarifas, pagamentos extras, impostos, gorjetas, pedágios, taxa de melhorias, taxa por congestionamento e taxa por corridas iniciadas em aeroporto. As colunas não possuem um valor especificado pelo dicionário de dados, no entanto, são necessárias para a análise de pagamentos então foi realizada consultas referentes a valores nulos, máximos, mínimos e valores negativos.

- Consulta 1: Valores nulos

```

SELECT
    fare_amount,
    extra,
    mta_tax,
    tip_amount,
    tolls_amount,
    improvement_surcharge,
    total_amount,
    congestion_surcharge,
    Airport_fee
FROM raw_taxi
WHERE fare_amount IS NULL
    OR extra IS NULL
    OR mta_tax IS NULL
    OR tip_amount IS NULL
    OR tolls_amount IS NULL
    OR improvement_surcharge IS NULL
    OR total_amount IS NULL
    OR congestion_surcharge IS NULL
    OR Airport_fee IS NULL;

```
- Consulta 2: Valores mínimos e máximo

```

SELECT
    MIN(fare_amount) AS fare_min,
    MAX(fare_amount) AS fare_max,

    MIN(extra) AS extra_min,
    MAX(extra) AS extra_max,

    MIN(mta_tax) AS mta_min,
    MAX(mta_tax) AS mta_max,

    MIN(tip_amount) AS tip_min,
    MAX(tip_amount) AS tip_max,

```

```

MIN(tolls_amount) AS tolls_min,
MAX(tolls_amount) AS tolls_max,

MIN(improvement_surcharge) AS improvement_min,
MAX(improvement_surcharge) AS improvement_max,

MIN(congestion_surcharge) AS congestion_min,
MAX(congestion_surcharge) AS congestion_max,

MIN(Airport_fee) AS airport_min,
MAX(Airport_fee) AS airport_max,

MIN(total_amount) AS total_min,
MAX(total_amount) AS total_max
FROM raw_taxi;

```

- Consulta 3: Valores negativos

```

SELECT
    fare_amount,
    extra,
    mta_tax,
    tip_amount,
    tolls_amount,
    improvement_surcharge,
    total_amount,
    congestion_surcharge,
    Airport_fee
FROM raw_taxi
WHERE fare_amount < 0
    OR extra < 0
    OR mta_tax < 0
    OR tip_amount < 0
    OR tolls_amount < 0
    OR improvement_surcharge < 0
    OR total_amount < 0
    OR congestion_surcharge < 0
    OR Airport_fee < 0;

```

Na análise foi possível verificar valores nulos nas colunas de taxa de congestionamento e de taxa de aeroporto, contudo, não é necessariamente um erro uma vez que pode apenas não ter sido adicionado mas faz-se necessário avaliar a necessidade de tratamento de tais dados. Também foi possível encontrar valores negativos, o que apresenta inconsistência com o escopo inicial uma vez que pagamentos não prevê valores negativos, mas também podem identificar estornos, cancelamentos ou ajustes de preço. Além disso, foram encontrados valores máximos muito altos para em gorjetas, essa informações pode não ser um erro mas mostra valores atípicos que podem ser analisados.

1.5 Distribuição para Verificação de Outliers

Mínimos, máximos, médias, medianas, percentis, quartis

- Consulta 1: estatísticas de cada coluna numérica (resultado de cada uma é agregado em uma tabela por uso de union all)

```

1 -- trip_distance
2 select 'trip_distance' as coluna, min(trip_distance) as min, max(trip_distance) as max,
3     round(avg(trip_distance), 2) as media,
4     round(quantile_cont(trip_distance, 0.1), 2) as p10, quantile_cont(trip_distance, 0.25) as q1,
5     quantile_cont(trip_distance, 0.5) as mediana,
6     quantile_cont(trip_distance, 0.75) as q3, round(quantile_cont(trip_distance, 0.9), 2) as p90
7 from raw_taxi

```

Resultado:

coluna varchar	min double	max double	media double	p10 double	q1 double	mediana double	q3 double	p90 double
trip_distance	0.0	312722.3	3.65	0.6	1.0	1.68	3.11	8.42
passenger_count	0.0	9.0	1.34	1.0	1.0	1.0	1.0	2.0
fare_amount	-899.0	5000.0	18.18	6.5	8.6	12.8	20.5	38.57
extra	-7.5	14.25	1.45	0.0	0.0	1.0	2.5	3.5
mta_tax	-0.5	4.0	0.48	0.5	0.5	0.5	0.5	0.5
tip_amount	-80.0	428.0	3.34	0.0	1.0	2.7	4.12	6.83
tolls_amount	-80.0	115.92	0.53	0.0	0.0	0.0	0.0	0.0
improvement_surcharge	-1.0	1.0	0.98	1.0	1.0	1.0	1.0	1.0
total_amount	-900.0	5000.0	26.8	12.5	15.38	20.1	28.56	53.4
congestion_surcharge	-2.5	2.5	2.26	2.5	2.5	2.5	2.5	2.5
airport_fee	-1.75	1.75	0.14	0.0	0.0	0.0	0.0	0.0

Ao analisar o resultado, é possível observar que várias colunas possuem quantias negativas e algumas possuem máximos grandes, mas dentro dos 10º a 90º percentil, os valores se encontram dentro do esperado.

1.6 Duplicidade

Existem valores duplicados que não poderiam? Algo com a ideia de ID por exemplo que deveria ser único

- Consulta 1: identifica e numera amostras com o mesmo VendorID, local de pickup, local de dropoff, horário de pickup, horário de dropoff, e distância de viagem, logo, mostra as que tem numero maior que 1 (duplicatas)

```

1 .print 'Tabela Duplicatas'
2 WITH number_duplicatas AS (
3     SELECT *, row_number() OVER (PARTITION BY vendorID, tpep_pickup_datetime, tpep_dropoff_datetime,
4         PULocationID, DOLocationID, trip_distance ORDER BY tpep_pickup_datetime) as list_duplicatas
5     FROM raw_taxi
6 )
7 SELECT * FROM number_duplicatas WHERE list_duplicatas > 1;

```

- Consulta 2: repete o que a consulta 1 fez, mas na tabela principal apenas com `total_amount > 0`

```

1 WITH number_duplicatas AS (
2     SELECT *, row_number() OVER (PARTITION BY vendorID, tpep_pickup_datetime, tpep_dropoff_datetime,
3         PUlocationID, DOlocationID, trip_distance ORDER BY tpep_pickup_datetime) as list_duplicatas
4     FROM raw_taxi_positive
5 )
6 SELECT * FROM number_duplicatas WHERE list_duplicatas > 1;

```

Após analisar os resultados de ambas as consultas, é possível identificar que a consulta 1 possui 31101 amostras (duplicatas), já a consulta 2, que consulta a tabela principal contendo apenas valores totais positivos, possui 0 amostras (duplicatas), logo, todas as duplicatas identificadas pela repetição de *VendorID*, *local de pickup*, *local de dropoff*, *horário de pickup*, *horário de dropoff*, e *distância de viagem* são fruto de um valor total negativo, que pode ser explicado pela devolução ou estorno do valor das corridas.

1.7 Cruzamento Simples Entre Colunas

Se colunas que são interligadas estão com os cálculos corretos

- Consulta 1: Mostra cada taxa, a soma de todas as taxas e *total_amount*

```

1 select fare_amount, extra, mta_tax, tip_amount, tolls_amount,
2     improvement_surcharge, congestion_surcharge, airport_fee,
3     round((fare_amount + extra + mta_tax + tip_amount + tolls_amount +
4     improvement_surcharge + congestion_surcharge + airport_fee), 2) as calculated_total,
5     total_amount
6 from raw_taxi;

```

- Consulta 2: Mostra cada taxa, a soma de todas as taxas, *total_amount*, e a diferença entre a soma das taxas e *total_amount*, apenas para amostras onde a soma e *total_amount* divergem

```

1 select fare_amount, extra, mta_tax, tip_amount, tolls_amount,
2     improvement_surcharge, congestion_surcharge, airport_fee,
3     round((fare_amount + extra + mta_tax + tip_amount + tolls_amount +
4     improvement_surcharge + congestion_surcharge + airport_fee), 2) as calculated_total,
5     total_amount, round(total_amount - calculated_total, 2) as difference
6 from raw_taxi where abs(difference) > 0;

```

- Consulta 3: Mostra os valores mais comuns de divergência

```

1 select difference, count(*) as frequencia from (
2     select round((fare_amount + extra + mta_tax + tip_amount + tolls_amount +
3         improvement_surcharge + congestion_surcharge + airport_fee), 2) as calculated_total,
4         total_amount, round(total_amount - calculated_total, 2) as difference
5     from raw_taxi where abs(difference) > 0
6 ) group by difference order by frequencia desc;

```

- Resultado da consulta 3:

difference double	frequencia int64
-2.5	591045
-4.25	22451
-1.75	18149
2.5	4244
1.95	23
-1.0	2
-0.3	1

Valores negativos indicam que o total calculado é maior que o *total_amount*, e valores positivos indicam o contrário.

Ao analisar os resultados, é possível observar uma frequência alta dos valores 1.75, 2.50 e 4.25 (vale ressaltar que $1.75 + 2.50 = 4.25$). Ao analisar os resultados da consulta 2 e observar cada taxa, as taxas que se destacam quando há diferença são a *airport_fee* (1.75) e a *congestion_surcharge* (2.50). Quando há divergência entre a soma e *total_amount*, essas taxas estão aplicadas na viagem, a diferença é exatamente o valor dessas taxas (ou a combinação delas), justificando a alta frequência dos valores 1.75, 2.50 e 4.25.

- Consulta 4: Mostra as amostras onde há divergência e também há *airport_fee* ou *congestion_surcharge*

```

1 select airport_fee, congestion_surcharge, round((fare_amount + extra + mta_tax + tip_amount +
2     tolls_amount + improvement_surcharge + congestion_surcharge + airport_fee), 2) as calculated_total,
3     total_amount, round(total_amount - calculated_total, 2) as difference
4 from raw_taxi where (airport_fee = 1.75 or congestion_surcharge = 2.5) and abs(difference) > 0;

```

A consulta 2 retornou 635915 amostras. A consulta 4 retornou 635535. Evidenciando que a maioria das diferenças entre a soma das taxas e o *total_amount* é causada pela *airport_fee* e/ou *congestion_surcharge*.

Porém, vale ressaltar que nem toda amostra onde essas taxas são aplicadas apresentam diferença entre a soma das taxas e o *total_amount*. Após fazer uma

quinta consulta, é possível observar que há 2047036 amostras onde *airport_fee* e/ou *congestion_surcharge* estão presentes e não há divergência entre a soma das taxas e *total_amount*.

- Consulta 5: Mostra as amostras onde NÃO há divergência e também há *airport_fee* ou *congestion_surcharge*

```
1 select airport_fee, congestion_surcharge, round((fare_amount + extra + mta_tax + tip_amount +
2 tolls_amount + improvement_surcharge + congestion_surcharge + airport_fee), 2) as calculated_total,
3 total_amount, round(total_amount - calculated_total, 2) as difference
4 from raw_taxi where (airport_fee = 1.75 or congestion_surcharge = 2.5) and abs(difference) = 0;
```

2. Tratamento

2.1 Decisões de Tratamento

- 1.2 - Nulos
 - Excluir VendorID 6
 - Estão em pouca quantidade e 100% do vendor 6 contém nulos
 - Excluir os nulos dos vendedores 1 e 2
 - Taxas de aeroporto e congestionamento alteram a soma total das taxas e podem criar diferenças com o total amount, por isso decidimos excluir as amostras onde esses campos são nulos
- 1.4 - Domínio Esperado
 - Remover corridas iniciadas em um ano diferente de 2024
 - Remover corridas iniciadas no mês de fevereiro
 - Gorjetas altas (remover?) - Mantém, valores não são exorbitantes
 - Pagamentos negativos (remover ou informar que são devoluções?) - Mantém em tabela separada, para manter salvo e guardado caso seja necessário o acesso (só na modelagem)
- 1.5 - Análise Estatística
 - O que fazer com os outliers e negativos? - Na coluna da distância, selecionamos os 1000 maiores valores e removemos os que se encontram acima da mediana desses valores
- 1.6 - Duplicatas
 - Excluir ou manter como devoluções? duplicatas negativas
 - Todas as duplicatas são negativas e têm uma corrida com valor positivo correspondente (vide 1.4).
- 1.7 - Validação dos valores somados
 - Zerar as taxas dos valores que estão dando a diferença ou adicionar essa diferença no total final? - Remover a taxa que está causando a

diferença nas amostras (*airport_fee* e/ou *congestion_subcharge*) quando for o caso, caso contrário remover a amostra.

2.2 Limpeza


- 1.2 - Nulos
 - Excluir linhas com o VendorID 6.
 - Excluir linhas com nulos dos VendorID 1 e 2.
- 1.4 - Domínio Esperado
 - Remover corridas iniciadas em um ano diferente de 2024.
 - Remover corridas iniciadas no mês de fevereiro.
- 1.5 - Análise Estatística
 - Analisar os outliers e achar um limiar para removê-los.
- 1.7 - Validação dos valores somados
 - Achar as linhas onde a soma dos valores diverge do total dado, achar onde isso é causado por *airport_fee* e/ou *congestion_surcharge* e zerar a taxa que causa a diferença nessas linhas. Nos outros casos de divergência, remover as linhas.

3. Modelagem

- a) Fato Corrida
- b) Dimensão Vendor
- c) Dimensão Tarifa
- d) Dimensão Pagamento - Dimensão Detalhes
- e) Dimensão Data
- f) Dimensão Localização - Dimensão Zona
- g) Dimensão Operação

[Link para o board](#)

Imagem 1: Modelagem



Fonte: Autoria própria, 2026

4. Consultas Analíticas

4.1 Financeiro

- Qual o valor médio pago por cada tipo de pagamento (cartão, dinheiro, etc)? -
A consulta revelou que o valor pago em média por cada tipo é: cartão de crédito - 28,00; dinheiro - 22,91; sem cobrança - 9,43; em disputa - 1,71
- Qual o volume e prejuízo total de devoluções realizadas?
A análise mostrou que houve 30743 devoluções, com o prejuízo total sendo 760612,66.
- Qual a média de valor de gorjetas para corridas com gorjeta?
A realização da consulta mostrou que o banco possui uma média no valor de 4.35 para as gorjetas.

4.2 Operacional

- Qual o faturamento em média por corrida e total de cada vendedor?
A consulta mostrou que o faturamento médio dos vendedores é de 25,87 para o vendedor 1 e 27,00 para o vendedor 2 com faturamento total de 56888183.27 para o vendedor 2 e 17305135.30 para o vendedor 1.
- Qual o tempo médio de viagem por faixas de distância (0-1 km, 1-3 km, 3-5 km, 5-10 km, 10+ km)?
A consulta revelou que na faixa de 0-1 milha, o tempo médio das corridas é 06'32", para 1-2 milhas é 12'55", para 3-5 milhas é 21'38", para 5-10 milhas é 26'43" e para 10+ milhas é 41'59".
- Qual a distância média percorrida de acordo com a quantidade de passageiros?
A análise dessa questão revelou que viagens com menos passageiros tendem a percorrer distâncias entre 2 e 4 milhas. No entanto, quantidades maiores de passageiros, como 7,8 e 9, mostram uma maior variação na distância, indo de 9, 7 e 1 milha respectivamente.

4.3 Localização

- Quais são as 5 rotas com a maior velocidade média?
A consulta revelou que a velocidade média das 5 rotas com maior velocidade média fica entre 38 e 43 milhas/hora e que 4 das 5 rotas mais velozes tem como origem e/ou destino um aeroporto (JFK e Newark).
- Quais são as 5 rotas que geram o maior faturamento total?
A verificação dessa questão revelou que as rotas que passam pelas zonas 132, 138, 237, 236, 265, 230 são as com maior faturamento.

- Quais são as zonas de embarque e desembarque mais comuns?

A análise mostrou que as zonas de embarque mais comuns são: JFK Airport, Upper East Side South, Midtown Center, Upper East Side North, Midtown East. Já as zonas de desembarque mais comuns são: Upper East Side North, Upper East Side South, Midtown Center, Times Sq/Theatre District, Lincoln Square East

4.4 Data

- Qual foram os 5 dias com maior volume de corridas e quais foram os 5 dias que geraram maior faturamento?

A consulta revelou que os dias 17, 18 e 25 estão no top 5 dias com mais corridas e maior faturamento, sendo o dia 25 o com maior faturamento de todos, enquanto o dia 27 teve o maior total de corridas, mas não está no top 5 de faturamento. O top 5 dias com mais corridas apresenta entre 98500 e 103500 corridas a cada dia, enquanto o top 5 faturamento faturou entre 2.650.000,00 e 2.850.000,00 cada dia.

- Qual o faturamento total e médio de acordo com cada faixa de horário (0h-6h, 6h-12h, 12h-18h, 18h-24h)?

O faturamento médio varia entre 25.52 e 27.19, sendo o horário entre 18h e 24h o momento de maior faturamento médio. O faturamento total varia entre 15728673.13 e 28316464.10, diferente do faturamento médio, o horário das 12h-18h tem o maior faturamento total.

- Quantas corridas são realizadas em cada faixa de horário no total (0h-3h, 3h-6h, 6h-9h, ..., 21h-24h)?

Para cada faixa de horário foi encontrada as quantidades de corridas indicadas na imagem abaixo (imagem 2). A consulta permitiu perceber que os horários entre 12h e 21h são os de maior movimento.

Imagem 2: Corridas por faixa horária

faixa_horario varchar	total_corridas int64
00h-03h	150073
03h-06h	50118
06h-09h	218682
09h-12h	397763
12h-15h	493468
15h-18h	556885
18h-21h	525350
21h-24h	383751

Fonte: Autoria própria, 2026